Problem Set 03

Đọc dữ liệu trong một dự án AI

Giảng viên: Nguyễn Bích Vân

IAI-UET-VNU · UET.MAT1052

Tất cả bối cảnh và số liệu của bộ này là giả lập mới để học. Không phải nhật ký sản phẩm thật, điểm của sinh viên thật hoặc một kết quả khảo sát thực tế. Tên A/B và các nhóm không đại diện cho sản phẩm thương mại. Kết luận chỉ áp dụng cho dữ liệu trong đề hoặc trong giả thiết đã nêu.

Câu hỏi xuyên suốt

Một biểu đồ có thể đúng số, nhưng câu kết luận đi kèm có đúng câu hỏi không?

Bộ đề gồm **10 bài, 54 câu hỏi**: 5 bài tính tay và 5 bài thực hành Python. Các bài đi từ đọc một chuỗi xử lý, phân biệt số đếm–tỉ lệ–mật độ, tới chia nhóm, cơ chế trọng số và kiểm tra những kết luận quá mạnh.

Cách làm và nộp bài

1. Bài 1–5: viết bằng tay trên giấy hoặc trên máy bằng bút điện tử, trình bày phép tính và lập luận. Máy tính cầm tay chỉ hỗ trợ số học; không chạy mã để thay cho bài làm.
2. Bài 6–10: dùng pandas xử lý bảng, plotnine vẽ hình. Notebook có mẫu riêng để học cú pháp, còn kết quả bài tập do bạn tự tính và giải thích.
3. Trước mỗi tỉ lệ, nói rõ những gì nằm trong mẫu số. Nêu cách xử lý dữ liệu thiếu; không thay ô thiếu bằng 0 tùy tiện.
4. Đồ thị cần có tên biến, đơn vị và biên khoảng. Giữ thang đo nhất quán khi so sánh. Báo cáo hình dạng, không chỉ vài số trung bình.
5. Nộp phần tính tay và notebook đã lưu kết quả. Mỗi bài Python cần một đoạn diễn giải; mã chạy được chưa thay thế lập luận thống kê.

Quy ước số học: giữ số chưa làm tròn khi tính; kết quả phần trăm có thể làm tròn 2–4 chữ số thập phân. SD là SD mẫu (mẫu số $n-1$); phân vị Python dùng nội suy tuyến tính. Chênh lệch hai phần trăm được gọi là *điểm phần trăm*.

Dữ liệu và lộ trình làm bài

Các CSV đã nằm trong `data/`; **không phải tải từ Internet**. Mỗi bài Python đọc lại đúng tệp của mình để tránh kế thừa nhầm bộ lọc của bài trước.

Bài	Tệp trong data/	Một hàng là
1	`exercise01_chatbot.csv`	Một lượt thử
6	`exercise06_responses.csv`	Một truy vấn của trợ lý học tập.
7	`exercise07_annotations.csv`	Một phiên gán nhãn ảnh.
8	`exercise08_ai_projects.csv`	Một sản phẩm AI được đánh giá.
9	`exercise09_deployments.csv`	Một lượt đã hoàn thành.
10	`exercise10_image_requests.csv`	Một yêu cầu được tiếp nhận.
Mẫu	`demo_drink_orders.csv`	Một đơn đồ uống; chỉ học cú pháp.

Bài 1–5 có đầy đủ bảng số ngay trong đề.

Số dòng dữ liệu với các bài thực hành Python: Bài 6: 960; Bài 7: 420; Bài 8: 240; Bài 9: 1.200; Bài 10: 1.000. Đây là số hàng trước xử lý thiếu. Bài 6–8 có một số ô trống để thực hành xác định tập quan sát hợp lệ; Bài 9–10 có đủ các biến dùng trong bài.

Bắt đầu trong VS Code

Mở thư mục đã giải nén, mở `00_Learn_Plotnine.ipynb`, chọn kernel Python và chạy từ trên xuống. Sau đó chuyển sang notebook làm bài. Kết quả hiện dưới từng ô mã.

```
from pathlib import Path
import re
import numpy as np
import pandas as pd
from plotnine import (
    ggplot, aes, geom_histogram, after_stat, geom_col,
    geom_bar, geom_point, geom_boxplot, facet_wrap, labs
)
DATA = Path("data")
```

Đọc **Hướng dẫn thực hành plotnine** đi kèm để hiểu từng lệnh, cách cài thư viện đúng kernel và cách chuyển mã mẫu sang câu hỏi riêng. `DATA_DICTIONARY.md` giải thích tên cột, đơn vị và chính sách giá trị thiếu.

Phân biệt quan trọng: tệp giả lập không phải bằng chứng thực nghiệm về sản phẩm hoặc con người thật. Các câu hỏi về "cơ chế có thể xảy ra" yêu cầu nêu khả năng và giới hạn suy luận, không đoán một nguyên nhân duy nhất từ hình.

Phần A — Tính tay

Bài 1 — Một buổi thử trợ lý học tập

`id` là mã lượt thử, `task` là loại tác vụ. Nhóm phát triển một trợ lý học tập thử ba loại yêu cầu: trả lời câu hỏi thường gặp (`FAQ`), tóm tắt văn bản (`Summarization`) và hỗ trợ lập trình (`Code`). Bảng dưới ghi 12 lượt thử. `input_tokens` là số đơn vị văn bản đầu vào; `response_time_s` là thời gian nhận đủ câu trả lời; `score` là điểm chất lượng trên thang 0–10.

id	task	input_tokens	response_time_s	score
1	FAQ	120	1.1	9
2	FAQ	240	1.4	8
3	FAQ	320	2.2	7
4	FAQ	400	4.0	9
5	Summarization	180	1.7	8
6	Summarization	600	3.2	9
7	Summarization	450	2.6	8
8	Summarization	800	4.5	7
9	Code	250	2.8	6
10	Code	500	3.8	8
11	Code	700	4.2	9
12	Code	200	3.0	7

Nhóm chỉ muốn xem các lượt có đầu vào ít nhất 200 token và thời gian phản hồi dưới 4 giây. Trong tập đó, câu trả lời đạt yêu cầu nếu điểm từ 8 trở lên. **Không chạy Python**; hãy đọc và thực hiện bằng tay chuỗi sau:

```
results = (
    thu_nghiem
    .query("input_tokens >= 200 and response_time_s < 4")
    .assign(passed=lambda d: d["score"] >= 8)
    .groupby("task", observed=True)
    .agg(n=("id", "size"),
         pass_rate=("passed", "mean"),
         mean_response_time_s=("response_time_s", "mean"))
)
```

Câu hỏi

1. Ghi ID của các lượt còn lại sau bước lọc. Chú ý các giá trị đúng bằng 200 token hoặc 4 giây.
2. Với từng lượt vừa giữ, điền giá trị `passed` là `True` hay `False`.
3. Lập bảng theo tác vụ gồm số lượt, tỉ lệ đạt và thời gian phản hồi trung bình. Ghi cả phép tính, không chỉ kết quả.
4. Giải thích vì sao trung bình của một cột `True/False` chính là một tỉ lệ; mẫu số ở đây là gì?
5. Giả sử thay cách làm bằng: tính token trung bình và thời gian trung bình của từng tác vụ trên toàn bộ 12 lượt, rồi chỉ giữ nhóm có hai trung bình thỏa ngưỡng. Cách này có trả lời cùng câu hỏi với chuỗi trên không? Phân biệt lọc từng lượt với lọc một bảng đã tổng hợp.

Bài 2 — Chờ một bức ảnh: cột cao nhất nói gì?

Trong một buổi thử công cụ tạo ảnh minh họa cho bài thuyết trình, nhóm ghi thời gian từ lúc gửi yêu cầu đến khi nhận được ảnh. Có 240 lượt được chia thành bốn khoảng sau. Khoảng cuối có tính cả đầu mút 12 giây.

Thời gian (giây)	Số lượt
$[0, 2)$	36
$[2, 3)$	60
$[3, 6)$	90
$[6, 12]$	54

Các khoảng không rộng bằng nhau. Ta muốn biểu diễn phần trăm lượt bằng *diện tích* hình chữ nhật, chứ không bằng chiều cao.

Câu hỏi

1. Tính phần trăm lượt trong từng khoảng.
2. Tính chiều cao histogram mật độ theo công thức h_i = phần trăm trong khoảng/độ rộng khoảng. Ghi rõ đơn vị của h_i.
3. Vẽ histogram trên giấy, giữ đúng độ rộng các khoảng trên trục thời gian. Kiểm tra tổng diện tích bằng 100%.
4. Khoảng nào có nhiều lượt nhất? Khoảng nào có mật độ lượt cao nhất trên mỗi giây? Hai câu trả lời có trùng nhau không?
5. Một bạn thấy cột từ 2 đến dưới 3 giây cao hơn cột từ 3 đến dưới 6 giây rồi nói: "Có nhiều lượt chờ 2–3 giây hơn 3–6 giây." Hãy giải thích bạn ấy đã đọc nhầm điều gì.

Bài 3 — Hai nhật ký gợi ý mã, cùng một histogram

Một tiện ích gợi ý mã chỉ lưu histogram thời gian phản hồi, không lưu từng thời gian riêng lẻ. Nhật ký gồm 14 lượt, đo bằng số nguyên mili giây (ms):

Khoảng (ms)	Số lượt
$[100, 200)$	4
$[200, 300)$	6
$[300, 400)$	3
$[400, 500)$	1

Các khoảng đều lấy đầu trái, bỏ đầu phải. Ta muốn biết histogram này còn cho phép khôi phục được gì về nhật ký gốc.

Câu hỏi

1. Tự lập hai danh sách A và B khác nhau, mỗi danh sách 14 số nguyên, đều có bảng tần số trên. Các số được phép lặp lại.
2. Trong A, đưa mọi số sát mép trái nhất có thể. Trong B, đưa mọi số sát mép phải nhất có thể nhưng vẫn thuộc khoảng. Giải thích vì sao không thể dùng đầu phải.
3. Không dùng trung bình hoặc độ lệch chuẩn, hãy nêu ít nhất ba thông tin về các lượt gốc mà histogram không cho biết chính xác.
4. Dùng A và B để phản biện: "Hai nhật ký có histogram giống nhau thì chất lượng phản hồi coi như giống hệt." Chỉ ra một khác biệt thực tế mà histogram đã che.

Bài 4 — GPU bận lâu hay có nhiều phiên chạy?

Một nhóm sinh viên theo dõi 100 phiên thử huấn luyện mô hình nhỏ. Thời lượng mỗi phiên, tính bằng phút, được tổng hợp như sau:

Thời lượng (phút)	Số phiên
$[0, 5)$	10
$[5, 15)$	20
$[15, 30)$	35
$[30, 60]$	35

Bảng đếm **số phiên**, không ghi tổng số phút GPU đã hoạt động. Mỗi phiên được tính đúng một lần.

Câu hỏi

1. Tính phần trăm phiên trong mỗi khoảng.
2. Tính chiều cao histogram mật độ với đơn vị phần trăm trên mỗi phút.
3. Hai khoảng cuối đều có 35 phiên. Trên histogram mật độ, cột nào cao hơn và cao gấp mấy lần? Minh họa bằng hình vẽ đúng tỉ lệ trục ngang.
4. Từ bảng, có thể kết luận số phiên dài đúng 20 phút nhiều hơn số phiên dài đúng 45 phút không? Vì sao?
5. Một bạn vẽ bốn cột rộng bằng nhau và cao 10,20,35,35. Hình này có thể là biểu đồ cột của bốn nhãn khoảng, nhưng tại sao không thể đọc như histogram trên trục phút liên tục?

Bài 5 — Phụ đề tự động: đổi nơi ghi âm, đổi tỉ lệ gộp

Một ứng dụng tạo phụ đề được đánh giá trên 300 đoạn âm thanh. Một đoạn được đánh dấu $H = 1$ nếu phụ đề có ít nhất 90% từ đúng theo bản đối chiếu; ngược lại $H = 0$. Kết quả theo điều kiện ghi âm là:

Điều kiện ghi âm	Số đoạn đạt	Số đoạn đánh giá
Phòng yên tĩnh	108	120
Lớp học	65	100
Ngoài trời	28	80

Các đoạn được chấm cùng một tiêu chí. Bảng không cung cấp thông tin về người nói hoặc cách phân công các đoạn âm thanh.

Câu hỏi

1. Tính tỉ lệ đạt trong từng điều kiện ghi âm và trong toàn bộ 300 đoạn.
2. Viết tỉ lệ gộp dưới dạng trung bình có trọng số của ba tỉ lệ theo nhóm. Trọng số mỗi nhóm là gì?
3. Một báo cáo chỉ nêu tỉ lệ gộp rồi kết luận: “Điều kiện ghi âm không giúp ích nhiều khi dự đoán đoạn nào đạt.” Bảng có ủng hộ kết luận đó không?
4. Giả sử các tỉ lệ theo nhóm giữ nguyên. Ước tính tỉ lệ đạt cho 100 đoạn mới gồm 20 đoạn phòng yên tĩnh, 30 đoạn lớp học và 50 đoạn ngoài trời.
5. Làm lại với cơ cấu 60,30,10 đoạn. So sánh hai tỉ lệ mới và giải thích tại sao chúng có thể khác dù ứng dụng không thay đổi. Đây là ước tính theo giả thiết hay kết quả đã quan sát trên 100 đoạn mới?

Phần B — Thực hành Python

Bài 6 — Chatbot FAQ có thật sự phản hồi tập trung hơn?

Tệp `exercise06_responses.csv` ghi 960 lượt dùng trợ lý học tập, gồm tra cứu câu hỏi thường gặp (`FAQ`) và giải thích mã (`Code explanation`). Mỗi hàng là một lượt; `response_time_s` là thời gian từ lúc gửi đến khi nhận đủ phản hồi. `id` là mã truy vấn, `task` là loại tác vụ. Một số thời gian bị thiếu do bản ghi không đầy đủ; không thay ô trống bằng 0.

Câu hỏi: hai nhóm khác nhau về **phân phối thời gian phản hồi** như thế nào, chứ không chỉ nhóm nào được dùng nhiều hơn?

```
phan_hoi = pd.read_csv(DATA / "exercise06_responses.csv")
x = phan_hoi.dropna(subset=["task", "response_time_s"]).copy()
edges = np.arange(0, 21, 1)
```

Câu hỏi

1. Vẽ hai histogram số đếm theo tác vụ, dùng chung các biên 0,1,2,...,20 giây. Giữ cùng thang trục ngang và trục dọc; có thể dùng `facet_wrap`.
2. Báo cáo số hàng ban đầu, số thời gian thiếu và số lượt hợp lệ trong từng tác vụ. Vì sao một nhóm có cột cao hơn chưa chắc có phân phối tập trung hơn?
3. Vẽ lại trên thang mật độ phần trăm/giây, chuẩn hóa riêng trong từng tác vụ. Tính bảng tần số để kiểm tra diện tích mỗi histogram bằng 100%.
4. Viết 4–6 câu so sánh vị trí, độ trải rộng, đuôi và vùng chồng lấp. Có thể bổ sung trung vị và khoảng tứ phân vị, nhưng không thay toàn bộ nhận xét bằng hai số trung bình.
5. Nếu dùng khoảng rộng 1 giây cho FAQ nhưng 3 giây cho giải thích mã, việc so sánh có vấn đề gì? Nêu cách trình bày giúp người đọc kiểm tra được kết luận.

Bài 7 — Vì sao thời gian gán nhãn hay kết thúc bằng 0 hoặc 5?

Trong một đợt làm bộ ảnh huấn luyện, người tham gia ghi thời lượng phiên gán nhãn bằng hai cách: tự ước lượng (`Self-reported`) hoặc dùng bộ bấm giờ (`Stopwatch`). Tệp `exercise07_annotations.csv` có 420 phiên. `recording_method` ghi cách đo, `id` là mã phiên. Cột `duration_min` được lưu ở độ phân giải một phút; giá trị hợp lệ là số nguyên dương. Ô trống nghĩa là chưa ghi được thời lượng.

Ta muốn tìm hiểu *cách ghi số* có để lại dấu vết trên dữ liệu hay không. Không có bảng thời gian chuẩn độc lập để đối chiếu.

```
nhan_anh = pd.read_csv(DATA / "exercise07_annotations.csv")
x = nhan_anh.dropna(subset=["duration_min", "recording_method"]).copy()
```

Câu hỏi

1. Kiểm tra dữ liệu hợp lệ, báo cáo số phiên được giữ và tạo chữ số hàng đơn vị bằng phép chia lấy dư cho 10. Không làm tròn thêm dữ liệu.
2. Lập bảng số đếm và tỉ lệ cho đủ 10 chữ số 0–9; vẽ biểu đồ cột tỉ lệ.
3. Thêm mốc 10% vào biểu đồ và so sánh. Giải thích vì sao mốc “10 chữ số đều nhau” chỉ là tham chiếu mô tả, chưa phải kiểm định hay một quy luật bắt buộc.
4. Tính tỉ lệ thời lượng kết thúc bằng 0 hoặc 5. Có hiện tượng dồn số tại hai chữ số này không?
5. Lặp lại theo `recording_method`; chuẩn hóa riêng trong mỗi cách ghi. Báo cáo cả cỡ nhóm và tỉ lệ kết thúc bằng 0 hoặc 5.
6. Nêu ít nhất hai cơ chế hợp lý có thể tạo ra hiện tượng dồn số. Biểu đồ có đủ để nói người tham gia “ghi sai” hoặc “không làm việc thật” không? Cần thêm dữ liệu gì để phân biệt các cơ chế?

Bài 8 — Một cụm điểm sát 70 có đáng nghi?

Tệp `exercise08_ai_projects.csv` ghi 240 sản phẩm AI nhỏ được đánh giá qua ba đợt. Mỗi hàng là một sản phẩm, với điểm chất lượng, độ ổn định và trình bày. Tổng điểm được tính theo

$$\text{tổng} = 0.5\,\text{chất lượng} + 0.3\,\text{ổn định} + 0.2\,\text{trình bày},$$

rồi làm tròn một chữ số thập phân. Điểm ở thang 0–100; có một số ô thiếu trong bản trích. Mốc 70 được dùng làm mốc tham chiếu khi thảo luận sản phẩm.

Tên cột trong bảng:

`id`	Mã sản phẩm.
`evaluation_round`	Đợt đánh giá.
`quality_score`	Điểm chất lượng.
`stability_score`	Điểm độ ổn định.
`presentation_score`	Điểm trình bày.
`total_score`	Tổng điểm đã ghi.

Một thành viên nhìn biểu đồ gộp và nói: "Có một đỉnh ngay trên 70, chắc kết quả đã được sửa để qua mốc." Hãy kiểm tra mức độ mà dữ liệu hỗ trợ phát biểu này.

```
san_pham = pd.read_csv(DATA / "exercise08_ai_projects.csv")
x = san_pham.dropna(subset=["total_score", "evaluation_round"]).copy()
```

Câu hỏi

1. Vẽ histogram tổng điểm với các biên 0,5,10,...,100. Ghi số tổng điểm hợp lệ và không quy ô thiếu thành 0.
2. Vẽ lại với các biên 0,1,2,...,100; giữ cùng miền trục ngang. Chỉ ra những khoảng có số sản phẩm lớn.
3. Đặc điểm nào vẫn thấy ở cả hai cách chia? Đỉnh nhỏ hoặc khoảng trống nào phụ thuộc cách chia? Có thể khẳng định chính xác số mốt của một phân phối nền từ đây không?
4. Chia theo đợt đánh giá, dùng cùng biên và thang đo. Cụm quanh 70–73 đến chủ yếu từ đâu? Kiểm tra bằng số sản phẩm có tổng điểm thuộc khoảng từ 70 đến dưới 73 trong từng đợt.
5. Chuyển ba cột điểm thành phần sang dạng dài, vẽ cùng một kiểu histogram. Mẫu hình gần 70 có chỉ xuất hiện ở tổng điểm không?
6. Viết kết luận không quá 120 từ: nêu bằng chứng mô tả, một số cơ chế khác có thể giải thích, và điều gì chưa thể kết luận về việc sửa kết quả.

Bài 9 — Cấu hình nào nhanh hơn: đọc bảng gộp hay bảng theo nhóm?

Một nhóm thử hai cấu hình triển khai A và B cho cùng loại trợ lý AI. `configuration` ghi cấu hình; `id` là mã lượt. Tệp `exercise09_deployments.csv` chỉ lưu 1.200 lượt **đã hoàn thành**, mỗi hàng là một lượt. Cột `input_length_group` ghi nhóm đầu vào `Short`, `Medium`, `Long`; `response_time_s` là thời gian hoàn thành. Các lượt ở hai cấu hình không được ghép cặp và cơ cấu độ dài không nhất thiết giống nhau.

Một bạn báo cáo: "Trung bình của A nhỏ hơn, vậy A luôn nhanh hơn B." Trong bài này, mọi so sánh bằng số về "nhanh hơn" đều dùng **thời gian trung bình**; các hình phân phối cung cấp bối cảnh bổ sung.

```
trien_khai = pd.read_csv(DATA / "exercise09_deployments.csv")
x = trien_khai.dropna(subset=["configuration", "input_length_group", "response_time_s"]).copy()
```

Câu hỏi

1. Tính số lượt, thời gian trung bình và trung vị theo cấu hình; vẽ boxplot hoặc histogram để so sánh phân phối gộp.
2. Lặp lại đúng các tóm tắt trên trong từng nhóm độ dài. Vẽ biểu đồ theo nhóm với cùng loại biểu đồ và thang đo.
3. So sánh dấu và độ lớn của chênh lệch trung bình A trừ B ở mức gộp và trong từng nhóm. Kết luận gộp có giữ cùng chiều trong mọi nhóm không?
4. Lập bảng tỉ phần các nhóm độ dài trong A và trong B. Dùng bảng này viết lại mỗi trung bình gộp thành trung bình có trọng số của ba trung bình nhóm.
5. Bộ dữ liệu này có sự đảo chiều theo nghĩa Simpson đối với trung bình hay chỉ là chênh lệch nhỏ đi? Giải thích tiêu chí; giảm độ lớn thôi đã đủ để gọi là đảo chiều chưa?
6. Vì chỉ có các lượt hoàn thành, có thể dùng kết quả để khẳng định cấu hình nào tốt hơn với mọi yêu cầu hoặc cấu hình gây ra thời gian chờ ngắn hơn không? Nêu dữ liệu hoặc cách đánh giá bổ sung cần thiết.

Bài 10 — Nhiều lượt tạo ảnh lỗi nhất có phải là dễ lỗi nhất?

Một dịch vụ tạo ảnh cho câu lạc bộ lưu toàn bộ 1.000 yêu cầu đã tiếp nhận trong đợt thử; `id` là mã yêu cầu. Cột `concurrent_requests` là số yêu cầu *khác* đang được xử lý lúc yêu cầu mới đến; `failed`=1 nếu không trả được ảnh hợp lệ trong 60 giây, bằng 0 nếu trả được. Cột `processing_mode` có hai mức `Standard` và `Economy`. Mỗi yêu cầu được tính đúng một lần, kể cả yêu cầu thất bại.

Một bạn lọc riêng các lượt thất bại, thấy một khoảng tải có nhiều lượt nhất rồi nói: "Yêu cầu ở khoảng đó có khả năng thất bại cao nhất." Hãy kiểm tra bằng cùng các khoảng tải $[0, 10), [10, 20), \ldots, [40, 50)$.

```
tao_anh = pd.read_csv(DATA / "exercise10_image_requests.csv")
edges = [0, 10, 20, 30, 40, 50]
```

Câu hỏi

1. Lọc các lượt thất bại và vẽ histogram tải với các biên đã cho. Hình này mô tả phân phối của tải trong tập quan sát nào?
2. Quay lại dữ liệu đầy đủ, đếm tất cả yêu cầu trong từng khoảng tải. Không dùng bảng đã lọc thất bại làm mẫu số.
3. Tính tỉ lệ thất bại trong mỗi khoảng. Viết bằng lời cả tử số và mẫu số. Quy định cách xử lý nếu một khoảng không có yêu cầu.
4. Vẽ hai biểu đồ riêng: số lượt thất bại và tỉ lệ thất bại theo khoảng tải. Ghi rõ đơn vị trục dọc.
5. Báo cáo khoảng có nhiều lượt thất bại nhất và khoảng có tỉ lệ thất bại cao nhất. Chúng có giống nhau trong dữ liệu này không?
6. Chỉ ra lỗi mẫu số trong câu kết luận ban đầu. Nêu thêm một ví dụ đời sống, ngoài bối cảnh tạo ảnh, có cùng lỗi suy luận.
7. Chia thêm theo chế độ xử lý, tính lại số yêu cầu và tỉ lệ thất bại trong từng tổ hợp chế độ–khoảng tải. Mẫu hình thay đổi thế nào? Không suy ra tác động nhân quả của chế độ.