UET.MAT1052 / XÁC SUẤT THỐNG KÊ

Problem Set 04

Đọc đúng một đường hồi quy trong dự án AI

Giảng viên: Nguyễn Bích Vân -IAI-UET-VNU

Bối cảnh và số liệu được biên soạn mới để học. Không phải nhật ký sản phẩm, điểm của sinh viên thật hay kết quả đánh giá một hệ thống thương mại.

Mục tiêu và cách làm

Bộ đề gồm **10 bài, 39 câu hỏi**: Bài 1–6 làm tay (60 điểm); Bài 7–10 lập luận và kiểm chứng (40 điểm). Mỗi bài 10 điểm. Trong Bài 7 và Bài 9 có hai nhiệm vụ notebook: LAB01 và LAB02. Hai câu thực hành này bổ sung việc kiểm chứng cho phần lập luận, không thay thế bài tính tay.

1. Bài 1–6: trình bày các tổng, bảng trung gian, biến đổi và đơn vị. Không dùng Python để thay phần làm tay.
2. Trước khi diễn giải hệ số, chỉ rõ một hàng là gì, biến đáp ứng, biến giải thích, đơn vị và mức tham chiếu.
3. Dùng $e_i = y_i - \hat{y}_i$, $SSE = \sum e_i^2$. So sánh SSE giữa các mô hình chỉ khi cùng tập quan sát, cùng biến đáp ứng và cùng cách tính mất mát.
4. Không làm tròn sớm khi tính. Có thể báo hệ số đến 4–6 chữ số thập phân. Phân biệt "giá trị khớp" với giá trị thực tế và "liên hệ" với "tác động nhân quả".
5. Nộp bài viết hoặc PDF cho câu hỏi, cùng notebook đã chạy và đoạn nhận xét. Hình cần có tên biến, đơn vị và chú giải khi có nhóm.

Phạm vi

Nội dung là **tương quan và hồi quy**: Pearson, OLS, phần dư, đổi thang đo, biến chỉ báo, cấu trúc nhóm, sai lầm suy diễn cấp độ và giới hạn nhân quả. Không yêu cầu kiểm định hệ số, p-value hay khoảng tin cậy.

Dữ liệu và cách dùng notebook

Các CSV đã có trong `data/`; không cần tải dữ liệu từ Internet. Các hàng trong CSV tính tay trùng đúng bảng của đề; chỉ dùng để kiểm chứng *sau khi đã làm tay.*

Phần	Tên CSV	Số hàng
Bài 1	`exercise01_prompt_tuning.csv`	5
Bài 2,4	`exercise02_response_time.csv`	4
Bài 3,5	`exercise03_execution_modes.csv`	12
Bài 7	`exercise07_hardware_groups.csv`	54
Bài 8	`exercise08_team_summary.csv`	12
Bài 9	`exercise09_forward_reverse.csv`	9
Học mẫu	`demo_drink_orders.csv`	12

Bài 6 cho sẵn các phương trình giả định; Bài 10 dùng các mô hình trong đề. Không có CSV bắt buộc khác.

Chỉ cần sửa ô cấu hình

Mở `00_Regression_Template.ipynb`, chạy ví dụ đồ uống trước, rồi thay cấu hình để làm LAB01 hoặc LAB02. Giữ tệp `regression_tools.py` cạnh notebook.

```
CONFIG = {
    "file": "demo_drink_orders.csv",
    "x": "item_count",
    "y": "wait_time_min",
    "group": "service_mode",  # None neu khong chia nhom
    "reference": "Standard",
    "x_label": "So mon trong don",
    "y_label": "Thoi gian cho (phut)",
    "x_new": 3,
}
```

Đây là mẫu độc lập để học thao tác, không phải lời giải có sẵn của LAB01/LAB02. Kết quả phân tích chỉ trở thành câu trả lời khi bạn đọc hình, giải thích hệ số và nêu giới hạn đúng ngữ cảnh. Xem **PS04_AI_Practice_Guide.pdf** để biết cách chọn kernel, cài thư viện, thay dữ liệu và lưu hình.

Phần A — Tính tay (60 điểm)

Bài 1 — Năm lần chỉnh trợ lý: tương quan nhỏ có nghĩa là không liên hệ?

Một nhóm thử năm mức `temperature` để điều chỉnh cách sinh câu trả lời. Mỗi mức được chấm chất lượng trên cùng một bộ câu hỏi nhỏ, thang 0–100. Đây là năm lượt thử giả lập, không phải một mẫu đủ lớn để kết luận cho mọi trợ lý AI. Gọi x là `temperature`, y là `quality_score`.

Lượt	x	y
T01	0.2	72
T02	0.4	84
T03	0.6	90
T04	0.8	82
T05	1.0	72

Câu hỏi

1. Tính $\bar{x}$ và $\bar{y}$.
2. Lập bảng năm cột $x_i - \bar{x}$, $y_i - \bar{y}$, $(x_i - \bar{x})(y_i - \bar{y})$, $(x_i - \bar{x})^2$, $(y_i - \bar{y})^2$; cộng từng cột cần dùng.

3. Không tính qua s_x, s_y, hãy dùng

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}.$$

   Nêu dấu và độ lớn của kết quả.

4. Một bạn kết luận: "Tương quan gần 0, vậy chỉnh temperature không giúp biết gì về chất lượng." Nêu hai lý do khác nhau vì sao kết luận này quá mạnh.

Bài 2 — Tự dựng đường dự đoán thời gian phản hồi

Một trợ lý học tập trả về bốn câu trả lời có độ dài khác nhau. $x =$ `output_hundreds` là độ dài đầu ra tính theo *trăm token*; $y =$ `response_time_s` là thời gian nhận đủ câu trả lời, tính bằng giây.

Yêu cầu	x: trăm token	y: giây
R01	2	6
R02	4	11
R03	2	10
R04	4	13

Ta khớp $\hat{y} = b_0 + b_1 x$ bằng bình phương tối thiểu, có hệ số chặn.

Câu hỏi

1. Tính $\bar{x}, \bar{y}$, rồi tính $b_1 = S_{xy}/S_{xx}$ và $b_0 = \bar{y} - b_1\bar{x}$.
2. Tính $\hat{y}_i$, $e_i = y_i - \hat{y}_i$ cho bốn yêu cầu. Kiểm tra bằng tay $\sum e_i = 0$ và $\sum x_i e_i = 0$.
3. Tính $SSE = \sum e_i^2$, ghi rõ đơn vị.
4. Đổi sang số token thực tế $x^* = 100x$. Không khớp lại, hãy viết đường hồi quy theo x^*, diễn giải hệ số góc mới và cho biết Pearson r thay đổi thế nào.

Bài 3 — Thêm chế độ chạy: tốt hơn toàn bộ, kém hơn ở một tập con

Nhóm thử hai chế độ `Standard` (thường) và `Accelerated` (tăng tốc). Gọi $D = 1$ cho Accelerated, $D = 0$ cho Standard. Hai mô hình OLS có hệ số chặn đã được khớp trên cùng **12 lượt hoàn thành** trong CSV đi kèm:

$$M_0: \ \hat{y} = 2.5 + 0.5x, \qquad M_1: \ \hat{y} = 4 + 0.5x - 3D.$$

x là `input_hundreds`, số trăm token đầu vào; y là thời gian phản hồi (giây). Chỉ dùng bốn lượt dưới đây để tính tay, **không khớp lại mô hình trên bốn lượt**.

ID	x	y	mode
S03	6	6	Standard
S04	8	7	Standard
A01	2	3	Accelerated
A06	12	8	Accelerated

Câu hỏi

1. Với mỗi mô hình, tính $\hat{y}, e, e^2$ cho cả bốn lượt.
2. Tính SSE_0, SSE_1 trên riêng tập con bốn lượt. Mô hình nào có SSE nhỏ hơn trên tập con này?
3. Chỉ ra một lượt mà thêm biến chế độ làm sai số bình phương tăng. Giải thích vì sao ngay cả kết quả so sánh trên cả tập con cũng không mâu thuẫn với việc thêm biến không làm SSE tối thiểu tăng trên cùng toàn bộ tập huấn luyện.

Bài 4 — Tự tìm ba hệ số, không gọi hàm hồi quy

Quay lại đúng bốn yêu cầu ở Bài 2. Bây giờ giữ thêm chế độ chạy. Đặt $W = 1$ nếu Accelerated, $W = 0$ nếu Standard.

Yêu cầu	x	y	W
R01	2	6	1
R02	4	11	1
R03	2	10	0
R04	4	13	0

Khớp $\hat{y} = b_0 + b_1 x + b_2 W$ trên **chính bốn hàng này**.

Câu hỏi

1. Từ $\sum e_i = 0, \sum x_i e_i = 0, \sum W_i e_i = 0$, lập hệ ba phương trình theo b_0, b_1, b_2.
2. Giải hệ. Viết hai đường khớp tương ứng với Standard và Accelerated.
3. Tính bốn phần dư và SSE. So sánh với Bài 2.
4. Giải thích bằng quan hệ giữa hai lớp mô hình vì sao thêm một biến giải thích không làm SSE tối thiểu tăng, khi OLS dùng cùng các hàng, cùng biến đáp ứng, cùng trọng số và không thêm ràng buộc hay phạt.

Bài 5 — Đổi nhóm tham chiếu mà không đổi dự đoán

Dùng M_1 ở **Bài 3**, không dùng mô hình Bài 4:

$$\hat{y} = 4 + 0.5x - 3D, \qquad D = I(\text{Accelerated}).$$

x là số trăm token đầu vào, y tính bằng giây. Trong tập huấn luyện, $2 \le x \le 12$. Standard hiện là mức tham chiếu.

Câu hỏi

1. Đặt $H = 1$ cho Standard và $H = 0$ cho Accelerated. Biến đổi đại số để viết mô hình $\hat{y} = a_0 + a_1 x + a_2 H$.
2. Với $x = 9$, tính giá trị khớp cho hai chế độ bằng cả hai cách mã hóa.
3. Khi đổi mức tham chiếu, đại lượng nào giữ nguyên: dự đoán cho từng chế độ, hệ số chặn, dấu của hệ số biến chỉ báo, hay khoảng cách giữa hai đường?
4. Có nên gọi hệ số chặn mới là thời gian phản hồi thực tế của một yêu cầu có 0 token không? Giải thích.

Bài 6 — Ba tác vụ, hai biến chỉ báo

Một báo cáo minh họa về trợ lý AI cung cấp hai phương trình sau (các hệ số được cho sẵn, không cần khớp dữ liệu):

$$M_1: \quad \hat{y} = 1.5 + 0.9x,$$

$$M_2: \quad \hat{y} = 2.4 + 0.5x + 1.8I(\text{Summarization}) + 4.2I(\text{Code}).$$

x là số trăm token đầu vào, y là thời gian phản hồi, tính bằng giây. `FAQ`: câu hỏi thường gặp; `Summarization`: tóm tắt; `Code`: hỗ trợ lập trình. FAQ là mức tham chiếu trong M_2. Đây là mô hình không có tương tác giữa độ dài và tác vụ.

Câu hỏi

1. Với $x = 6$, tính dự đoán của M_2 cho cả ba tác vụ.
2. Đổi mức tham chiếu sang Summarization. Viết lại toàn bộ phương trình của M_2 bằng hai biến chỉ báo thích hợp.
3. Kiểm tra lại dự đoán cho một yêu cầu Code với $x = 6$ bằng phương trình mới.
4. Diễn giải hệ số góc 0.9 của M_1 và 0.5 của M_2. Vì sao chúng khác nhau không có nghĩa phần mềm tính sai?

Phần B — Lập luận và thực hành (40 điểm)

Bài 7 — Gộp ba môi trường phần cứng, dấu tương quan đổi chiều

Một nhóm triển khai trợ lý trên `Edge` (thiết bị biên), `Workstation` (máy trạm) và `Cloud` (đám mây). Mỗi môi trường có 18 lượt hoàn thành; x là số token đầu ra, y là thời gian phản hồi. Dữ liệu giả lập nằm trong `exercise07_hardware_groups.csv`. Từ cùng các cặp hợp lệ, các hệ số tương quan được làm tròn như sau:

Phạm vi	Pearson r
Toàn bộ 54 lượt	−0.6203
Edge	+0.8000
Workstation	+0.6000
Cloud	+0.7500

Bốn con số này đã được cung cấp; ở câu 1–4, hãy giải thích trước khi chạy mã.

Câu hỏi

1. Bốn hệ số có thể đồng thời đúng không? Phác hoặc mô tả vị trí của ba cụm điểm để giải thích.
2. Để trả lời "trong cùng môi trường, đầu ra dài hơn thường đi kèm phản hồi lâu hơn hay nhanh hơn?", nên dùng hệ số gộp hay hệ số theo nhóm?
3. Một bạn viết: "Vì tương quan gộp âm, yêu cầu chatbot viết dài hơn sẽ làm nó trả lời nhanh hơn." Chỉ ra hai lỗi logic khác nhau.
4. Nếu chỉ thêm một biến vào hồi quy $y \sim x$, bạn chọn biến nào? Giải thích theo cấu trúc, không theo p-value.
5. **Thực hành LAB01.** Đổi ô cấu hình của notebook sang CSV này, dùng `output_tokens`, `response_time_s`, nhóm `environment`, tham chiếu `Edge`. Vẽ scatterplot theo nhóm; khớp OLS

gộp và OLS cộng biến nhóm trên cùng các hàng; đọc hệ số x, so sánh dấu và viết 4–6 câu nhận xét.

Bài 8 — Từ nhóm dự án xuống từng yêu cầu: có được suy như vậy không?

Mỗi điểm là **một nhóm dự án**, không phải một yêu cầu riêng lẻ. Trong 12 nhóm giả lập, x là phần trăm yêu cầu dùng truy xuất tài liệu; y là phần trăm câu trả lời thiếu căn cứ. Các tỉ lệ là đại lượng tổng hợp giả lập; không kèm dữ liệu cấp yêu cầu. Miền x được quan sát là 30–85%.

$$r \approx -0.80, \qquad \hat{y} = 42 - 0.35x.$$

Các phần trăm dùng thang 0–100. Xét bốn phát biểu:

A. Nhóm có tỉ lệ dùng truy xuất cao hơn có xu hướng có tỉ lệ câu trả lời thiếu căn cứ thấp hơn.

B. Một yêu cầu dùng truy xuất có xác suất thiếu căn cứ thấp hơn yêu cầu không dùng truy xuất đúng 0.35 điểm phần trăm.

C. Buộc một nhóm tăng tỉ lệ dùng truy xuất 20 điểm phần trăm sẽ làm tỉ lệ trả lời thiếu căn cứ giảm 7 điểm phần trăm.

D. Dữ liệu gợi ý một liên hệ tuyến tính âm ở cấp nhóm, nhưng chưa xác định cơ chế nhân quả.

Câu hỏi

1. Phân loại A–D: được hỗ trợ ở mức mô tả, không suy ra từ cấp dữ liệu hiện có, hoặc khẳng định nhân quả vượt dữ liệu. Giải thích từng lựa chọn.
2. B và C mắc hai lỗi khác nhau. Gọi tên và phân biệt hai vấn đề đó.
3. Nêu một biến gây nhiễu hợp lý ở cấp nhóm và giải thích nó có thể góp phần tạo ra liên hệ âm như thế nào.

Bài 9 — Đảo công thức không phải là đổi bài toán dự đoán

Dữ liệu `exercise09_forward_reverse.csv` gồm 9 lượt trả lời của một trợ lý. Đặt $x =$ `output_hundreds`, $y =$ `response_time_s`. Các tóm tắt được làm tròn:

$$\bar{x} = 6, \qquad \bar{y} = 12.8, \qquad r = 0.60, \qquad \hat{y} = 8 + 0.8x.$$

Một bạn muốn ước lượng độ dài đầu ra từ thời gian và viết $\hat{x} = (y - 8)/0.8$.

Câu hỏi

1. Phương trình vừa đảo có tự động là đường OLS dự đoán x từ y không?
2. Dùng $b_{y|x} = r\, s_y/s_x$ và $b_{x|y} = r\, s_x/s_y$ để tìm điều kiện hai hệ số góc là nghịch đảo. Nêu rõ giả thiết về độ biến thiên và trường hợp $r = 0$.
3. Giải thích bằng hình học vì sao tối thiểu hóa sai số theo y và tối thiểu hóa sai số theo x là hai việc khác nhau.
4. Từ các tóm tắt, tính hệ số góc và hệ số chặn của hồi quy x theo y. So sánh với phương trình giải ngược tại $y = 14$ giây.
5. **Thực hành LAB02.** Chọn CSV và hai cột ở đầu bài trong notebook. Khớp hai chiều riêng biệt; kiểm tra $b_{y|x} b_{x|y} = r^2$, kiểm tra chúng đi qua $(\bar{x}, \bar{y})$, vẽ hai đường trên cùng hệ trục (x, y). Không so SSE của hai chiều như thể chúng có cùng đơn vị.

Bài 10 — Bốn báo cáo AI: sửa kết luận, không chỉ sửa công thức

Đọc bốn đoạn báo cáo độc lập dưới đây. Mọi dữ liệu và mô hình đều là minh họa.

I — Ngoài vùng thử. Một mô hình $\hat{t} = 0.8 + 0.3x + 0.6z$ mô tả thời gian trả lời (giây), với x, z là độ dài đầu vào/đầu ra theo trăm token. Nó chỉ được khớp với $1 \le x \le 10$, $1 \le z \le 6$. Báo cáo dùng $x = 25, z = 18$ và gọi kết quả là "dự đoán đáng tin cậy vì công thức vẫn tính được".

II — Hệ số chặn. Từ M_1 của Bài 3, báo cáo gọi số 4 là "thời gian phản hồi thực tế điển hình cho yêu cầu Standard không có token đầu vào".

III — Bỏ qua môi trường. Từ dữ liệu Bài 7, báo cáo lấy slope gộp âm làm "quy luật chung của cả Edge, Workstation và Cloud".

IV — Chính sách. Từ Bài 8, báo cáo kết luận: "Bắt mọi nhóm tăng dùng truy xuất sẽ làm tỉ lệ trả lời thiếu căn cứ giảm đúng tốc độ 0.35".

Câu hỏi

1. Với mỗi trường hợp, gọi tên bẫy chính bằng một cụm từ ngắn.
2. Viết lại mỗi kết luận thành một câu thận trọng nhưng vẫn có ích, phù hợp với dữ liệu/mô hình hiện có.
3. Chọn một trường hợp và đề xuất dữ liệu hoặc thiết kế đánh giá bổ sung để có kết luận mạnh hơn. Giải thích điều bổ sung đó xử lý điểm yếu nào.

Tra cứu tên cột Anh–Việt

Tên trong CSV	Ý nghĩa tiếng Việt
`run_id`, `request_id`	Mã lượt thử hoặc yêu cầu. Đây là định danh, không phải biến số để hồi quy.
`temperature`	Tham số điều chỉnh cách sinh câu trả lời trong tình huống Bài 1.
`quality_score`	Điểm chất lượng 0–100. Không phải xác suất.
`output_hundreds`	Độ dài đầu ra tính theo trăm token: 2 nghĩa là 200 token.
`input_hundreds`	Độ dài đầu vào tính theo trăm token.
`output_tokens`	Số token đầu ra, đơn vị một token (khác cột trên).
`response_time_s`	Thời gian nhận đủ phản hồi, tính bằng giây.
`mode`	Standard = thường; Accelerated = tăng tốc.
`environment`	Edge = thiết bị biên; Workstation = máy trạm; Cloud = đám mây.
`team_id`	Mã nhóm dự án; một hàng Bài 8 là một nhóm.
`retrieval_usage_pct`	Phần trăm yêu cầu dùng truy xuất trong nhóm, thang 0–100.
`unsupported_answer_pct`	Phần trăm trả lời thiếu căn cứ trong nhóm, thang 0–100.
`order_id`, `item_count`	Mã đơn và số món trong ví dụ đồ uống học cú pháp.
`wait_time_min`	Thời gian chờ đồ uống, tính bằng phút.
`service_mode`	Standard = phục vụ thường; Express = phục vụ nhanh trong ví dụ mẫu.

Các tên tạo thêm trong mã mẫu: `x`, `y` là bí danh hai cột đã chọn; `group` là bí danh cột nhóm. `fitted` là giá trị khớp, `residual` là phần dư. `simple`, `adjusted`, `reverse` lần lượt là hồi quy đơn, hồi quy thêm biến nhóm và hồi quy theo chiều ngược.

Dữ liệu hiện có không có ô thiếu. Mã mẫu vẫn kiểm tra thiếu, giá trị vô hạn, cột không có độ biến thiên và hạng ma trận để sinh viên thay bằng dữ liệu khác an toàn hơn. Các dòng bị loại phải được báo cáo; không thay số thiếu bằng 0.