Từ CSV đến một đường hồi quy

Nguyễn Bích Vân -IAI-UET-VNU

1. Mở đúng thư mục, chọn đúng Python

Giải nén gói vào một thư mục riêng. Trong VS Code, chọn **File → Open Folder**, mở thư mục có các tệp sau:

```
PS04_AI_Student/
    PS04_AI_Exercises.pdf
    PS04_AI_Practice_Guide.pdf
    00_Regression_Template.ipynb
    PS04_AI_Student.ipynb
    regression_tools.py
    regression_example.py
    requirements.txt
    data/
        demo_drink_orders.csv
        exercise07_hardware_groups.csv
        exercise09_forward_reverse.csv
        ...
```

Mở `00_Regression_Template.ipynb`, chọn **Select Kernel** ở góc trên bên phải rồi chọn một môi trường Python. Cần cài tiện ích Python và Jupyter của Microsoft trong VS Code nếu chưa có.

Thiếu thư viện: tạo một ô Code trong notebook và chạy:

```
%pip install -r requirements.txt
```

Sau khi cài, chọn **Restart Kernel**, rồi **Run All**. Lệnh `%pip` chạy trong môi trường của kernel hiện tại. Không chép các dấu nhắc `PS D:...>` hay » vào ô mã.

> Trong notebook, **Shift+Enter chạy ô hiện tại**; kết quả nằm ngay bên dưới ô. Trong PowerShell, thao tác phím có thể khác. Không chạy các câu lệnh cài đặt của PowerShell trong ô Python.

2. Thay dữ liệu bằng một ô cấu hình

Lần đầu, chạy nguyên notebook mẫu. Ví dụ đồ uống giả lập giúp học cú pháp mà chưa làm hộ các bài được giao.

```
CONFIG = {
    "file": "demo_drink_orders.csv",
    "x": "item_count",
    "y": "wait_time_min",
    "group": "service_mode",
    "reference": "Standard",
    "x_label": "So mon trong don",
    "y_label": "Thoi gian cho (phut)",
    "x_new": 3,
}
```

`file` phải là tên CSV trong `data/`. `x`, `y` là hai cột số; `group` là cột phân loại hoặc `None`. `reference` là một nhãn có thật trong cột nhóm, không phải tên cột. Nhãn hiển thị `x_label`, `y_label` có thể bằng tiếng Việt mà không đổi tên CSV/cột.

LAB01 (Bài 7): thay bốn tên chính như sau:

```
"file": "exercise07_hardware_groups.csv",
"x": "output_tokens",
"y": "response_time_s",
"group": "environment",
"reference": "Edge",
"x_new": None,
```

LAB02 (Bài 9):

```
"file": "exercise09_forward_reverse.csv",
"x": "output_hundreds",
"y": "response_time_s",
"group": None,
"reference": None,
"x_new": None,
```

Các dòng trên là nội dung cần *thay trong từ điển CONFIG*, không phải một ô độc lập hoàn chỉnh. Sau khi sửa, khởi động lại kernel và chạy từ đầu. Với tệp dữ liệu riêng, chỉ cần đặt vào `data/` rồi thay các tên tương ứng; các kiểm tra đầu vào vẫn hoạt động.

3. Hiểu thao tác đọc và chuẩn bị dữ liệu

Đừng bỏ qua bước kiểm tra bảng. Đọc năm dòng đầu, số hàng/cột và các giá trị thiếu trước khi khớp mô hình.

```
from pathlib import Path
import pandas as pd

raw = pd.read_csv(Path("data") / "demo_drink_orders.csv")
display(raw.head())
print(raw.shape)
print(raw.dtypes)
print(raw.isna().sum())
```

`head()` cho năm hàng đầu, `shape` cho cặp (số hàng, số cột), `dtypes` cho kiểu dữ liệu. Một mã đơn như `001` không phải biến số để hồi quy.

Trong mã mẫu, hai cột được chọn được đặt bí danh `x`, `y` trong một bảng xử lý mới. CSV gốc không bị sửa:

```
data = pd.DataFrame({
    "x": pd.to_numeric(raw[CONFIG["x"]], errors="coerce"),
    "y": pd.to_numeric(raw[CONFIG["y"]], errors="coerce"),
})
if CONFIG["group"] is not None:
    data["group"] = raw[CONFIG["group"]]
data = data.dropna().copy()
```

`errors="coerce"` chuyển giá trị không đọc được thành số thiếu để phát hiện và loại khỏi phân tích, không âm thầm xem nó là 0. Hàm `prepare_data()` trong gói còn kiểm tra số vô hạn, nhãn nhóm trống và số cặp hợp lệ.

Cùng tập quan sát: khi so OLS đơn và OLS thêm nhóm, cả hai phải dùng cùng các hàng có đủ `x`, `y`, `group`. Nếu mỗi mô hình dùng một tập hàng khác, không thể áp dụng máy móc quy tắc "thêm biến không tăng SSE".

Cần biến thiên: nếu mọi giá trị `x` giống nhau hoặc mọi `y` giống nhau, Pearson không được định nghĩa. Mẫu sẽ dừng và báo rõ thay vì đưa ra một con số vô nghĩa.

4. Từ công thức sang statsmodels

Các lệnh dưới đây dùng bảng đã có hai cột `x`, `y`:

```
import statsmodels.formula.api as smf
r = data["x"].corr(data["y"])
m = smf.ols("y ~ x", data=data).fit()
display(m.params)

data["fitted"] = m.fittedvalues
data["residual"] = m.resid
SSE = (data["residual"] ** 2).sum()
print("Pearson r:", r)
print("SSE:", SSE)
```

`"y x"` đặt y là biến đáp ứng, x là biến giải thích; có hệ số chặn mặc định. `fit()` khớp mô hình. Trong `params`, `Intercept` là hệ số chặn, còn `x` là hệ số góc. Chỉ đọc các mục đang học; chưa cần diễn giải p-value trong `summary()`.

Hai thuộc tính `fittedvalues` và `resid` thỏa $y_i = \hat{y}_i + e_i$. SSE có đơn vị bình phương của y; phần dư có cùng đơn vị với y.

Với biến nhóm, chọn rõ mức tham chiếu:

```
m_group = smf.ols(
    'y ~ x + C(group, Treatment(reference="Standard"))',
    data=data
).fit()
display(m_group.params)
```

Dòng này dùng được khi nhóm có nhãn `Standard`. Với LAB01, thay bằng `Edge`. Với ba mức nhóm, có hai hệ số biến chỉ báo. Mô hình cộng nhóm không có tương tác nên các đường song song.

Hồi quy ngược phải khớp riêng:

```
reverse = smf.ols("x ~ y", data=data).fit()
print(m.params["x"] * reverse.params["y"])
print(r ** 2)
```

Hai dòng cuối dùng để đối chiếu một đẳng thức đại số. Không lấy nghịch đảo slope để thay cho `ols("x y", ...)`.

5. Vẽ với plotnine: bảng + ánh xạ + lớp hình

```
from plotnine import (
    ggplot, aes, geom_point, geom_abline,
    geom_hline, labs
)
p = (ggplot(data, aes(x="x", y="y"))
     + geom_point(size=2)
     + geom_abline(intercept=m.params["Intercept"],
                   slope=m.params["x"])
     + labs(x=CONFIG["x_label"], y=CONFIG["y_label"]))
display(p)
```

`ggplot` chọn bảng; `aes` nói cột nào đi vào trục; `geom_point` biểu diễn các quan sát; `geom_abline` thêm *đúng đường đã khớp*. Không bắt buộc dùng màu để hình có nghĩa.

Phần dư cần một đồ thị riêng:

```
p_res = (ggplot(data, aes(x="x", y="residual"))
         + geom_point(size=2)
         + geom_hline(yintercept=0, linetype="dashed")
         + labs(x=CONFIG["x_label"],
                y="Phan du (cung don vi voi y)"))
display(p_res)
```

Có biến nhóm: dùng `aes(color="group")` để ánh xạ màu theo nhóm. Mẫu trong `regression_tools.py` dùng `predict()` của mô hình đã điều chỉnh để tạo các đường cho nhóm. Nếu tự cho phần mềm khớp một đường riêng cho từng nhóm, đó có thể là lớp mô hình khác, không còn mô hình cộng nhóm có slope chung.

Lưu hình:

```
from pathlib import Path
out = Path("student_outputs")
out.mkdir(exist_ok=True)
p.save(out / "scatter.png", width=7, height=4.4, dpi=150)
p.save(out / "scatter.pdf", width=7, height=4.4)
```

`display(p)` hiện hình dưới ô notebook; `save()` tạo tệp. Khi chạy mẫu script, xem đường dẫn ảnh được in trong Terminal. Không cần mở cửa sổ đồ họa riêng để chương trình hoàn thành.

6. Từ output đến một bài làm hoàn chỉnh

Ở `PS04_AI_Student.ipynb`, đặt `RUN_LAB01=True` hoặc `RUN_LAB02=True` để chạy phần tương ứng. Mặc định hai cờ là `False` để bạn dự đoán trước khi nhìn kết quả. Đây không phải lỗi khi notebook báo LAB chưa chạy.

Một đoạn nhận xét nên có: đơn vị quan sát; hướng và dạng quan hệ; hệ số theo đúng đơn vị; phép so sánh có/không giữ nhóm; giới hạn của câu kết luận. "Mã chạy thành công" không trả lời thay các ý này.

Lỗi thường gặp

Không tìm thấy CSV. Mở đúng thư mục chứa `data/`; hoặc sửa `ROOT_OVERRIDE` thành đường dẫn tuyệt đối. Giữ dấu ngoặc kép khi đường dẫn có khoảng trắng.

Thiếu plotnine. Chạy lại lệnh cài ở Mục 1 bằng đúng kernel, rồi khởi động lại kernel. Máy có nhiều Python thì thư viện của một bản không tự xuất hiện trong bản khác.

Tên cột không đúng. Xem `raw.columns`. Tên cột và nhãn có phân biệt hoa/thường; không dùng tên tiếng Việt cũ.

Sai mức tham chiếu. Kiểm tra `data["group"].unique()`. Tham chiếu phải là một giá trị của cột nhóm, không phải tên của cột.

Không thấy biểu đồ trong Terminal. Kết quả notebook nằm dưới ô; mẫu script lưu ảnh. Xem `student_outputs/`.

Kết quả sau đổi CSV không nhất quán. Restart Kernel rồi Run All. Không giữ biến trung gian của lần chạy trước.

Tài liệu cú pháp chính thức

1. VS Code, Jupyter Notebooks: https://code.visualstudio.com/docs/datascience/jupyter-notebooks.
2. statsmodels, Fitting models using R-style formulas: https://www.statsmodels.org/stable/example_formulas.html.
3. plotnine, Save and display: https://plotnine.org/guide/export.html.